# Documento de Arquitetura: Mecanismo RAG (Ecossistema Mobile)

## 1. Visão Geral

Este documento especifica o mecanismo RAG (Retrieval-Augmented Generation) projetado para um aplicativo mobile corporativo. O objetivo central do sistema é a melhora contínua da comunicação, assertividade e clareza do usuário. Para alcançar essa meta, a aplicação utiliza técnicas de fonoaudiologia computacional e oratória como ferramentas de suporte para a detecção de vícios de linguagem (pleonasmos, solecismos, ambiguidades) e controle de ritmo de fala (BPM). A estrutura de recomendação e aprendizagem fundamenta-se em metodologias validadas de comunicação assertiva, retórica e técnicas de apresentação.

## 2. Arquitetura Mobile em Quatro Camadas

### 2.1. Camada de Processamento Acústico e Mitigação de Viés (Fine-Tuning)

Antes de acionar o RAG, a arquitetura emprega um modelo de Speech-to-Text (STT) submetido a fine-tuning com um dataset específico, composto por áudios de comunicadores e apresentadores de diversas regiões. O propósito fundamental desta camada é capacitar a inteligência artificial a diferenciar com precisão erros fonéticos reais (barbarismos) de sotaques e variações linguísticas regionais. Isso garante que o usuário não seja penalizado por sua regionalidade, atuando como um filtro crucial de mitigação de viés pré-transcrição.

### 2.2. Base de Conhecimento e Vetorização (Embeddings)

A base de dados vetorial armazena exercícios e fundamentos teóricos estruturados em eixos de desenvolvimento comunicativo:

- **Fundamentos e Redução de Ruídos:** Identificação de falhas no canal emissor-receptor devido a cacofonias e barbarismos.
- **Retórica e Oratória:** Exercícios baseados em Ethos, Pathos e Logos para estruturação de argumentos e engajamento do público.
- **Linguagem Corporal e Fisiologia:** Treinos práticos e respiração diafragmática voltados ao controle do nervosismo e do medo de falar em público.
- **Treino Articulatório:** Exercícios estruturados de fonoaudiologia, focados no fortalecimento da musculatura bucal e clareza fonética.

### 2.3. Gatilho de Recuperação (On-Device & Híbrido)

1. **Ingestão Mobile:** O usuário realiza gravações curtas (30 a 90 segundos) por meio do hardware do smartphone.
2. **Diagnóstico de Comunicação:** O backend analisa o BPM e identifica desvios gramaticais e sintáticos, além de vícios de linguagem, utilizando parâmetros fonoaudiológicos de apoio.
3. **Seleção de Conteúdo:** A busca vetorial localiza e recupera o módulo correspondente à deficiência identificada, recomendando conteúdos adequados ao contexto.

### 2.4. Geração Aumentada (LLM Prompting)

Nesta etapa, o RAG instrui a IA a compilar as correções pontuais da fala do usuário, combinando-as com a prescrição de exercícios práticos e conceitos teóricos de comunicação relevantes.

## 3. Especificação do Prompt Dinâmico de Injeção

Abaixo, a estrutura de contexto orquestrada pela aplicação:
**[Contexto do Sistema e Ética]**
Atue como um especialista em comunicação assertiva, utilizando conhecimentos de oratória e fonoaudiologia para apoiar o desenvolvimento do usuário.
**[Input do Usuário - Exemplo de Estrutura]**
Transcrição: "Vou-me já e... hum... falta três dias para a palestra e tô nervoso."
Diagnóstico: Cacofonia ("Vou-me já"), Solecismo ("falta três dias").
BPM: 165 (Ritmo acelerado, indicativo de ansiedade).
**[Contexto Recuperado - Base de Conhecimento]**
ID 12 (Teoria): Linguagem corporal e técnicas de relaxamento para falar em público.
ID 88 (Exercício): Prática de articulação voltada à correção de solecismos.
**[Instrução Final]**
Aponte o solecismo e a cacofonia de forma didática e construtiva. Prescreva o Exercício ID 88 para melhorar a clareza e recomende o conteúdo ID 12 com foco no controle da ansiedade e medo de apresentações.

## 4. Integração de Hardware Mobile

- **Microfone:** Responsável pela captação do áudio e extração do espectrograma, permitindo aferir o BPM exato e analisar padrões de pausas absolutas.
- **Câmera (Fase Futura):** Módulo de visão computacional opcional destinado ao treino de gesticulação, validando postura e linguagem corporal em tempo real.

## 5. Camada de Evolução Analítica e Privada (Diário de Bordo)

Para impulsionar o engajamento de forma condizente com o perfil corporativo, o sistema adota métricas analíticas e visuais baseadas em desenvolvimento contínuo, em substituição a mecânicas genéricas de gamificação:

- **Gráficos de Radar (Radar Charts):** Permitem a visualização do desempenho ao comparar eixos teóricos (Fundamentos da Assertividade, Retórica, Engajamento) com eixos práticos (Controle de BPM, Clareza Fonética e Ausência de Solecismos).
- **Árvores de Habilidades (Skill Trees):** Uma trilha de progressão estruturada que desbloqueia os conteúdos de forma lógica. O usuário refina a articulação e corrige barbarismos básicos antes de acessar etapas de formulação complexa de argumentos.
- **Privacidade e Segurança Psicológica:** Garantindo a confidencialidade, todos os gráficos e históricos de áudio são criptografados localmente (on-device) e acessíveis de forma exclusiva pelo usuário. O sistema é estritamente voltado para autoavaliação, evitando qualquer caracterização como ferramenta de avaliação ou vigilância corporativa.

## 6. Stack Tecnológica e Ecossistema

Para garantir a baixa latência e a viabilidade da plataforma, a arquitetura técnica utilizará as seguintes ferramentas:

- **Orquestrador e Backend:** API estruturada em Python (FastAPI) com integração via LangChain ou LlamaIndex para a orquestração do pipeline de dados.
- **Modelo de Transcrição (STT):** Google Cloud Speech-to-Text ou OpenAI Whisper, aplicados na camada acústica inicial.
- **Banco de Dados Vetorial:** ChromaDB, Qdrant ou Pinecone, garantindo alta performance na busca semântica de exercícios e teorias.
- **Modelo de LLM (Motor de Geração):** Google Gemini 1.5 Flash (devido à sua alta velocidade e natureza multimodal) ou Qwen 3.8 (como alternativa open-weights para eficiência e processamento robusto).